PHENIKAA UNIVERSITY

Khai phá dữ liệu lớn và học máy

ScholarLens

Hệ thống truy xuất bài báo arXiv với tìm kiếm lai, Graph RAG và chatbot hỏi đáp



NHÓM 2

L — **Dương Khánh Linh** — MSSV 25800037 — NHÓM TRƯỞNG

S — **Cao Đức Soạn** — MSSV 25800041

Q — **Triệu Minh Quang** — MSSV 25800042

D — **Nguyễn Thành Dương** — MSSV 25800030

Nội dung trình bày

1. **Giới thiệu hệ thống**
   ScholarLens là gì, chạy ở đâu
2. **Phát biểu bài toán**
   Vấn đề và các tình huống sử dụng
3. **Yêu cầu hệ thống**
   Chức năng và chất lượng vận hành
4. **Nguồn dữ liệu và thu thập**
   Lấy bài báo từ đâu, bằng cách nào
5. **Tổ chức dữ liệu**
   Các kho dữ liệu và mục đích của từng kho
6. **Hệ thống tìm kiếm**
   Kết hợp khớp từ khoá và khớp ý nghĩa
7. **Chatbot hỏi đáp**
   Trả lời có dẫn nguồn, gợi ý bài liên quan
8. **Báo cáo kỹ thuật**
   Kết quả đánh giá
9. **Trình bày giải pháp**
   Giao diện, demo và kết luận

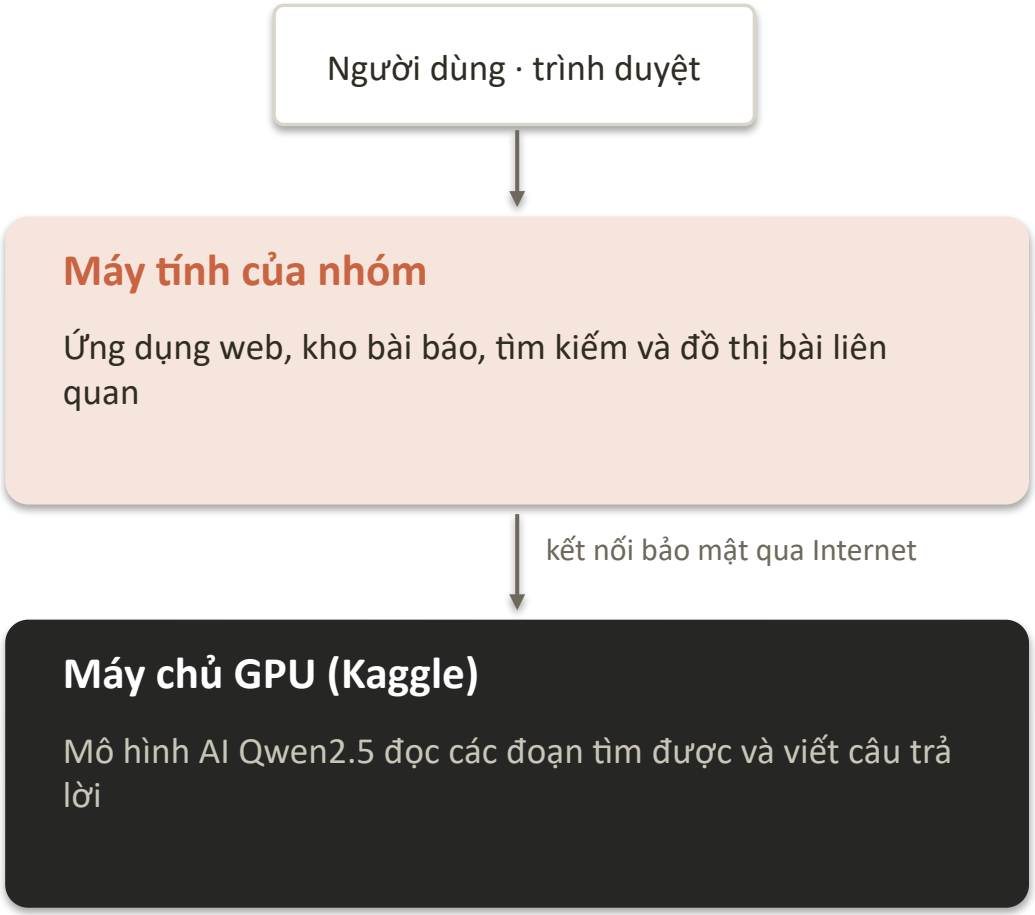
1. Giới thiệu hệ thống

ScholarLens là trợ lý **tìm kiếm và hỏi đáp** tài liệu khoa học.

1. **Tìm đúng bài**
   Hỏi bằng tiếng Việt, hệ thống tìm trong kho bài báo arXiv

2. **Trả lời có nguồn**
   Mỗi ý trong câu trả lời ghi rõ lấy từ bài nào, đoạn nào

3. **Gợi ý bài liên quan**
   Bài cùng tác giả, cùng chủ đề hoặc trích dẫn nhau



2. Phát biểu bài toán: tìm đúng bài, hỏi đúng chỗ

Hơn 20.000

bài mới trên arXiv mỗi tháng

Tìm theo từ khoá bỏ sót cách diễn đạt khác; LLM thuần dễ bịa nguồn. Cần truy xuất ngữ nghĩa + quan hệ giữa các bài + câu trả lời có trích dẫn.

1 Tìm bằng câu hỏi

Kết quả xếp hạng, có tác giả, năm, link arXiv

2 Thêm 1 PDF

Tự kiểm tra trùng, tự embedding và cập nhật đồ thị

3 Thêm hàng loạt PDF

Trạng thái riêng từng file: mới / trùng / lỗi

4 Hỏi về một bài

Trả lời từ chính bài đó, trích dẫn [n]

5 Hỏi bài liên quan

Láng giềng trên đồ thị kèm lý do liên quan

6 Trò chuyện chung

Chế độ Chat, không cần truy xuất

3. Yêu cầu hệ thống: hệ thống làm được gì

Chức năng chính

1. **Tự thu thập bài báo**
   Lấy bài mới từ kho arXiv theo chủ đề cần theo dõi

2. **Thêm tài liệu dễ dàng**
   Kéo-thả file PDF; tự nhận ra bài đã có, không lưu trùng

3. **Tìm đúng bài cần đọc**
   Hỏi bằng tiếng Việt như nói chuyện, ra bài phù hợp nhất

4. **Hỏi đáp có dẫn nguồn**
   Câu trả lời chỉ rõ lấy từ đoạn nào, của bài nào

5. **Gợi ý bài liên quan**
   Chỉ ra bài cùng tác giả, cùng chủ đề, hoặc trích dẫn nhau

Chất lượng vận hành

< 1 giây
để tìm ra bài liên quan

≈ 30 giây
để thêm một bài mới vào kho

Dễ dùng
Giao diện chat quen thuộc, không cần đào tạo

Đáng tin
Không có thông tin thì nói rõ, không tự bịa

Ổn định
Mất kết nối AI vẫn tìm kiếm và xem tài liệu được

4. Nguồn dữ liệu và phương thức thu thập

492	12	877	6
bài báo	bài có toàn văn PDF	đoạn văn đã xử lý	chủ đề thu thập

1 Kho arXiv, tự động

Hệ thống tự tải thông tin bài báo theo chủ đề hoặc lĩnh vực; bài quan trọng tải cả file PDF.

Dùng để cập nhật bài mới thường xuyên

2 Bộ dữ liệu arXiv trên Kaggle

Bản sao thông tin khoảng 2,7 triệu bài, nạp một lần với số lượng lớn.

Dùng khi cần mở rộng kho nhanh

3 Người dùng tải lên

Kéo-thả file PDF; hệ thống tự tra thông tin chuẩn của bài trên arXiv.

Dùng cho tài liệu riêng cần hỏi ngay

Thu thập đúng quy định của arXiv (nghỉ 3 giây giữa các lần gọi) và tự bỏ qua bài đã có.

5. Tổ chức dữ liệu phục vụ tìm kiếm

1

Thông tin bài báo

Lưu tiêu đề, tác giả, năm và nội dung từng đoạn; dùng để kiểm tra bài trùng

SQLite

2

Tìm theo ý nghĩa

Biến mỗi đoạn văn thành vector để tìm được câu cùng ý dù khác từ

ChromaDB

3

Tìm theo từ khoá

Tìm chính xác thuật ngữ, tên phương pháp, tên bộ dữ liệu

BM25

4

Quan hệ giữa các bài

Nối bài với tác giả, chủ đề, trích dẫn để gợi ý bài liên quan

Đồ thị NetworkX

Khi thêm một tài liệu mới

Kiểm tra đã có chưa → Đọc nội dung PDF → Ghi vào cả 4 kho → **Sẵn sàng tìm kiếm**

Bài đã có thì dừng ngay và báo lại, không lưu trùng. Toàn bộ quá trình mất khoảng 30 giây mỗi bài.

6. Hệ thống tìm kiếm: khớp từ khoá + khớp ý nghĩa



- **Chunk tóm tắt** (tiêu đề + abstract) giúp bài không có PDF vẫn tìm được; chunk nội dung 220 từ, chồng 40, gắn trang + section để trích dẫn.
- **Embedding đa ngôn ngữ** cho phép hỏi bằng tiếng Việt trên kho tiếng Anh; GPU fp16 trên Kaggle, CPU khi demo.

7. Chatbot: hai chế độ trò chuyện và nghiên cứu

Chat

- Trò chuyện, giải thích khái niệm
- Không truy xuất, phản hồi nhanh
- Gợi ý chuyển Research khi cần nguồn

Research

- Graph RAG + trích dẫn [n] bắt buộc
- Hỏi theo bài focus và bài liên quan
- Không đủ ngữ cảnh → nói rõ, không bịa

1	**Định tuyến**	focus / chào hỏi / mặc định
2	**Viết lại câu hỏi**	truy vấn tiếng Anh độc lập
3	**Hybrid search**	5 bài seed, 2 đoạn mỗi bài
4	**Mở rộng đồ thị**	láng giềng + quan hệ thành câu
5	**Sinh câu trả lời**	streaming SSE, trích dẫn [n]
6	**Lưu hội thoại**	kèm nguồn và đồ thị con

7. Chatbot: gợi ý bài liên quan qua đồ thị

4 loại nút

paper	bài báo	**492**
author	tác giả	**2.232**
concept	khái niệm (keyphrase)	**2.805**
category	chuyên mục arXiv	**69**

5 loại cạnh

CITES	paper → paper	**19**
SIMILAR_TO	cosine ≥ 0,75	**2.052**
WRITTEN_BY	paper → author	**2.354**
MENTIONS	paper → concept	**2.952**
IN_CATEGORY	paper → category	**881**

Điểm liên quan của q với p

$$\text{score} = 1[\text{CITES}] + \cos(\text{SIMILAR}) + \Sigma\, w(e) \,/\, \log_2(2 + \deg e)$$

- **Trích dẫn** (2 chiều, từ arXiv ID trong References): +1
- **Tương đồng nội dung** top-5 cosine ≥ 0,75 giữa vector bài
- **Cùng tác giả** w = 0,6 · cùng khái niệm w = 0,45 · cùng category 0,05
- **Khái niệm** trích bằng KeyBERT rút gọn: n-gram → cosine với bài → MMR
- **Kết quả kèm lý do:** “trích dẫn bài này · cùng khái niệm dense retrieval”

7. Chatbot: mô hình AI chạy trên máy chủ GPU

```
python -m scholarlens.llm_server \
    --preset qwen2.5-7b-awq --tunnel cloudflared
```

1. **Dò GPU** — T4 (cc 7.5) → float16; 2 GPU → tensor-parallel 2
2. **Chạy vLLM** — OpenAI API, prefix caching, enforce-eager trên T4
3. **Chờ sẵn sàng** — GET /v1/models trả 200, log ra data/llm_server
4. **Mở tunnel** — cloudflared hoặc ngrok → URL công khai
5. **In cấu hình** — 4 dòng .env + gọi thử một câu

Model gợi ý (preset)

preset	repo Hugging Face	GPU
qwen2.5-7b-awq	Qwen2.5-7B-Instruct-AWQ	2×T4
qwen2.5-3b	Qwen2.5-3B-Instruct	1×T4
qwen2.5-1.5b	Qwen2.5-1.5B-Instruct	1×T4
llama3.1-8b-awq	Llama-3.1-8B-Instruct AWQ	2×T4, HF_TOKEN
qwen2.5-14b-awq	Qwen2.5-14B-Instruct-AWQ	2×T4, 8k ctx

Bất kỳ repo Hugging Face nào vLLM hỗ trợ: --model <repo>; tham số lạ sau -- được chuyển thẳng cho vLLM.

8. Báo cáo kỹ thuật: kết quả đánh giá

Truy xuất known-item · 492 bài

0,957

BM25 · Recall@1

0,996

BM25 · Recall@10

0,973

BM25 · MRR@10

- **Giao thức:** truy vấn = tiêu đề, kho = abstract (không chứa tiêu đề), đáp án duy nhất là chính bài đó
- **So sánh:** BM25 · Dense (multilingual-e5, bge-base) · Hybrid RRF
- **Dense / Hybrid:** chạy scripts/evaluate.py trên máy GPU, rồi chạy lại reports/build_slides.py để slide tự điền biểu đồ

95%

bắt được tiêu đề bị biến đổi (dedup)

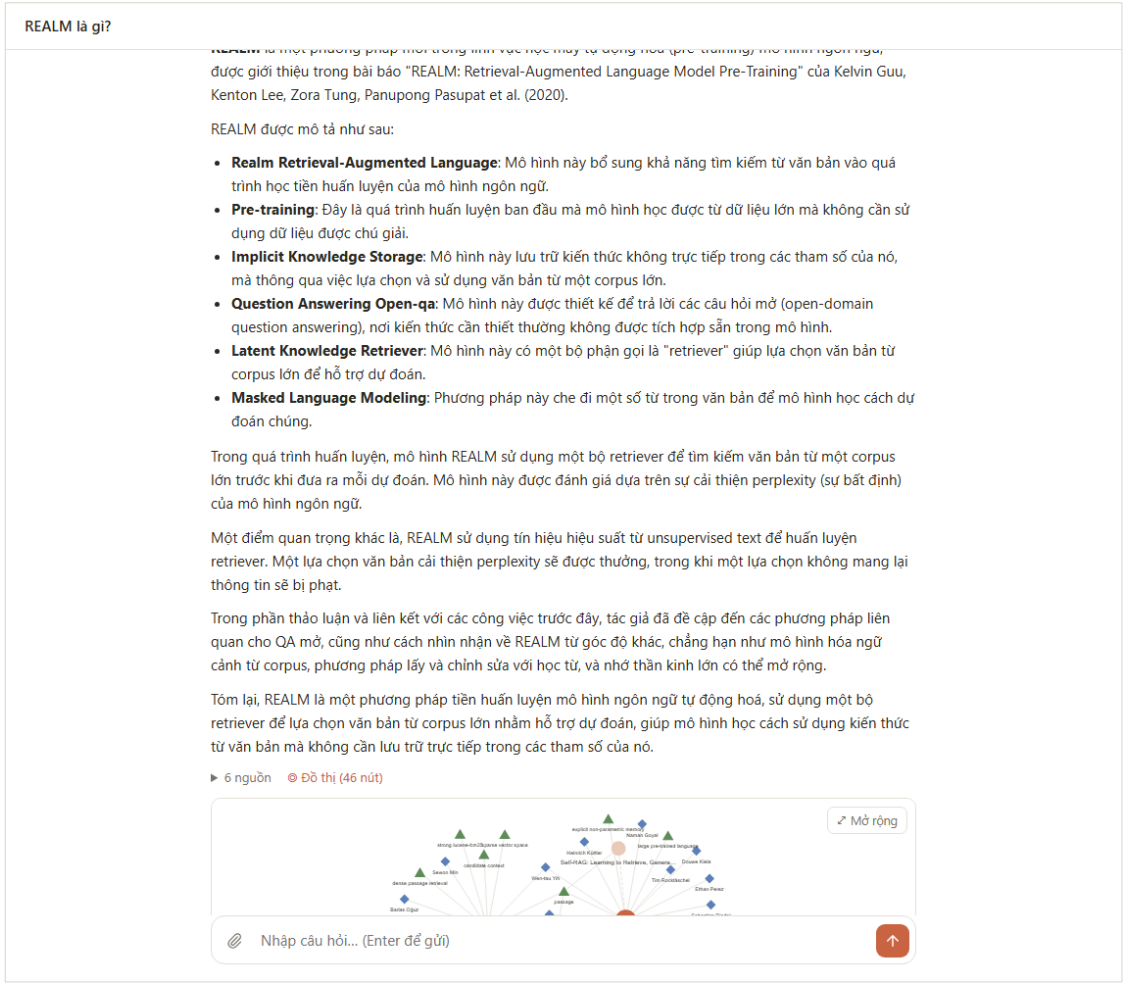
0%

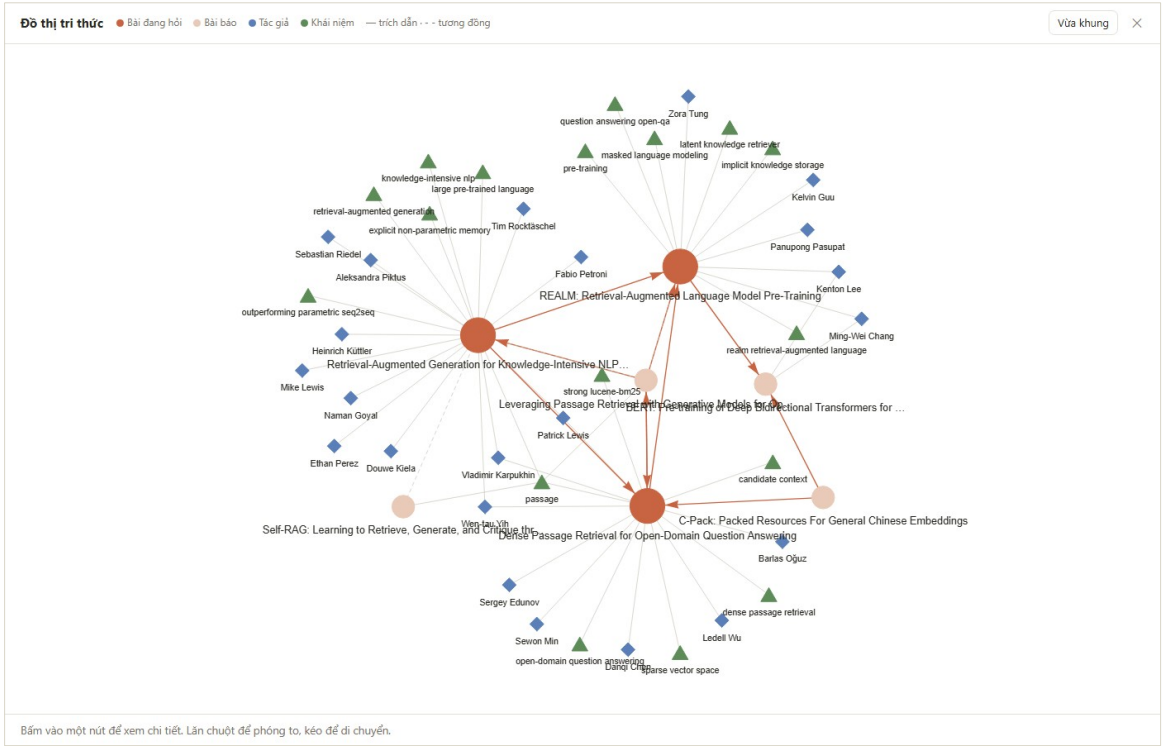
báo trùng nhầm trên 492 tiêu đề thật

37%

bài liên quan cùng category (ngẫu nhiên 14%)

9. Trình bày giải pháp: giao diện





- **Thanh bên thu gọn được:** lịch sử hội thoại và kết nối LLM
- **Mỗi câu trả lời:** trích dẫn [n], danh sách nguồn, đồ thị riêng
- **Đồ thị toàn màn hình:** bấm vào từng nút để xem chi tiết

9. Trình bày giải pháp: kịch bản demo

1	**Thêm 1 bài**	Kéo GraphRAG (2404.16130) vào cửa sổ → theo dõi 6 bước, bài tự thành focus
2	**Hỏi về bài**	“Tóm tắt bài này”, “Phương pháp chính là gì?” → trả lời có [n], bấm [n] để xem nguồn
3	**Bài liên quan**	“Các bài liên quan đến bài này?” → danh sách + lý do, bấm ◎ Đồ thị, mở rộng toàn màn hình
4	**Thêm trùng**	Kéo lại cùng file → “đã có (trùng SHA-256)”, không embedding lại
5	**Thêm hàng loạt**	Chọn 3 PDF còn lại → bảng trạng thái từng file, rồi “So sánh các bài vừa thêm”

9. Kết luận và hướng phát triển

Đã làm được

- Đủ chuỗi chức năng: thu thập → xử lý → tìm kiếm → hỏi đáp, AI tự vận hành trên GPU
- Thêm PDF tự động với 3 lần kiểm tra trùng
- Tìm kiếm lai + Graph RAG trả lời có trích dẫn, giải thích được bài liên quan
- Chạy được cả khi không có LLM (chế độ trích đoạn)

Hạn chế → hướng tiếp

- Parse PDF bằng heuristic → GROBID / Nougat cho bảng, công thức
- Trích dẫn chỉ qua arXiv ID → khớp tiêu đề tài liệu tham khảo, Semantic Scholar API
- Khái niệm bằng n-gram → trích thực thể, quan hệ bằng LLM (GraphRAG đầy đủ)
- Chưa có reranker → cross-encoder bge-reranker cho top-20

Cảm ơn thầy cô và các bạn đã lắng nghe